

# Laporan Praktikum Kontrol Cerdas

## Week 4

Nama : Adiesceasha akbar

NIM 224308001

Kelas : TKA-6A

Akun Github (Tautan) : <https://github.com/adiesakbar>

Student Lab Assistant : Muhammad Fatih Anfa Ahima (214308092)

### 1. Judul Percobaan

Reinforcement Learning for Autonomous Control

### 2. Tujuan Percobaan

Pada akhir praktikum ini, mahasiswa akan dapat:

1. Memahami konsep dasar Reinforcement Learning (RL) dalam sistem kendali.
2. Mengimplementasikan agen RL menggunakan algoritma Deep Q-Network (DQN).
3. Menggunakan OpenAI Gym sebagai simulasi lingkungan untuk pelatihan RL.
4. Melatih dan menguji agen RL untuk mengontrol lingkungan secara otonom.
5. Menggunakan GitHub untuk version control dan dokumentasi praktikum.

### 3. Landasan Teori

#### Apa itu Reinforcement Learning?

Reinforcement Learning (RL) adalah metode pembelajaran di mana agen belajar mengambil keputusan melalui interaksi dengan lingkungan. Agen memperoleh reward atau penalty sebagai umpan balik dari tindakannya, sehingga ia dapat mengoptimalkan strategi untuk mencapai tujuan tertentu.

#### Penerapan RL dalam Autonomous Control

Beberapa contoh penerapan RL antara lain:

- Navigasi Robot: Mengontrol pergerakan robot dalam lingkungan yang dinamis.
- Kendaraan Otonom: Mengambil keputusan berkendara berdasarkan kondisi lingkungan.
- Optimasi Rute dan Proses: Mengatur pergerakan dalam pabrik, gudang, atau sistem logistik

### 4. Analisis dan Diskusi

#### 1. Performa Agen dalam Mengontrol Environment CartPole

Agen menunjukkan peningkatan performa seiring dengan pelatihan, dengan skor yang meningkat dari awal hingga mencapai skor tinggi yang lebih stabil.

Dengan eksplorasi yang cukup pada awal pelatihan (epsilon tinggi) dan eksploitasi setelahnya (epsilon rendah), agen dapat mempelajari kebijakan yang lebih optimal untuk menjaga keseimbangan tiang pada kereta.

Jika agen sudah terlatih dengan baik, saat pengujian (epsilon rendah), seharusnya ia mampu mempertahankan tiang dalam keseimbangan lebih lama.

#### 2. Pengaruh Perubahan Parameter terhadap Kinerja Agen

Gamma (discount factor):

Gamma tinggi ( $\sim 0.99$ ) membuat agen lebih memperhatikan reward jangka panjang, yang cocok untuk tugas seperti CartPole.

Gamma terlalu rendah ( $\sim 0.5$ ) membuat agen lebih fokus pada reward jangka pendek, yang dapat menyebabkan perilaku suboptimal.

Epsilon (exploration rate):

Nilai awal epsilon tinggi (1.0) memungkinkan eksplorasi luas, tetapi perlu diturunkan secara bertahap untuk menghindari tindakan acak yang tidak efektif.

Epsilon yang menurun terlalu cepat menyebabkan eksplorasi tidak cukup, sedangkan terlalu lambat memperlambat proses belajar.

Learning rate:

Nilai optimal (0.001) memberikan keseimbangan antara kecepatan konvergensi dan kestabilan pelatihan.

Learning rate yang terlalu tinggi membuat pelatihan tidak stabil, sedangkan terlalu rendah menyebabkan pelatihan lambat.

### 3. Tantangan dalam Pelatihan Agen RL

Ketidakstabilan pembelajaran: Karena DQN memperbarui nilai Q berdasarkan estimasi sendiri, pembelajaran bisa menjadi tidak stabil.

Eksplorasi yang tidak optimal: Jika epsilon decay tidak diatur dengan baik, agen bisa gagal menemukan strategi optimal.

Overfitting pada lingkungan tertentu: Agen bisa sangat baik dalam satu environment tetapi buruk dalam generalisasi ke environment lain.

### Diskusi

#### 1. Perbedaan antara Reinforcement Learning dan Supervised Learning dalam Sistem Kendali

Supervised Learning membutuhkan data berlabel untuk pelatihan, sedangkan Reinforcement Learning belajar melalui interaksi dengan lingkungan tanpa label eksplisit.

RL lebih cocok untuk tugas kendali karena dapat menyesuaikan strategi berdasarkan umpan balik dari lingkungan tanpa perlu dataset berlabel.

#### 2. Optimasi Strategi Eksplorasi dan Eksploitasi dalam RL

Menggunakan Epsilon-Greedy Decay: Memulai dengan eksplorasi tinggi dan secara bertahap meningkatkan eksploitasi.

Menggunakan Upper Confidence Bound (UCB): Mengutamakan tindakan yang memiliki nilai ketidakpastian tinggi untuk eksplorasi yang lebih cerdas.

Menggunakan strategi Boltzmann Exploration: Memilih tindakan berdasarkan probabilitas yang bergantung pada nilai Q, bukan hanya nilai maksimum.

#### 3. Potensi Aplikasi RL dalam Sistem Kendali Nyata

Robotika: RL digunakan untuk mengontrol gerakan robot secara optimal dalam berbagai skenario.

Kendaraan Otonom: RL dapat digunakan untuk navigasi dan pengambilan keputusan dalam mobil tanpa pengemudi.




Sistem Manajemen Energi: RL digunakan untuk mengoptimalkan penggunaan energi di gedung pintar dan jaringan listrik.

Trading Saham: Agen RL digunakan untuk mempelajari strategi optimal dalam perdagangan saham dan kripto.

## 5. Assignment

- Modifikasi algoritma DQN dengan menambahkan teknik seperti target network untuk meningkatkan stabilitas pelatihan.
- Uji agen pada environment lain seperti LunarLander-v2 atau MountainCar-v0 dan bandingkan performanya.
- Eksperimen dengan variasi parameter dan dokumentasikan pengaruhnya terhadap kinerja agen.
- Upload semua hasil eksperimen ke GitHub dan buat laporan singkat mengenai analisis dan temuan Anda

## 6. Data dan Output Hasil Pengamatan

| No | Variabel                                                          | Hasil data                                                                          |
|----|-------------------------------------------------------------------|-------------------------------------------------------------------------------------|
|    | cartpole                                                          |   |
|    | modifikasi algoritma DQN dengan menambahkan teknik target network |   |
|    | environment LunarLander-v2                                        |  |

## 7. Kesimpulan

Target network meningkatkan stabilitas pelatihan, terutama dalam lingkungan yang kompleks seperti LunarLander-v2.

DQN yang dimodifikasi lebih adaptif pada berbagai environment, tetapi performanya tetap bergantung pada tuning parameter.

Eksplorasi yang cukup dan parameter yang tepat sangat berpengaruh terhadap keberhasilan agen RL dalam mencapai performa optimal.

GitHub membantu dalam version control dan dokumentasi, memudahkan eksperimen serta analisis perubahan model.

## 8. Saran

Dalam tugas ini, disarankan untuk memperluas eksplorasi metode Reinforcement Learning (RL) dengan membandingkan berbagai algoritma seperti Deep Q-Network (DQN), Proximal Policy Optimization (PPO), dan Soft Actor-Critic (SAC) dalam pengendalian sistem otonom. Selain itu, analisis mendalam terhadap parameter hiper (seperti laju pembelajaran, discount factor, dan ukuran replay buffer) dapat memberikan wawasan mengenai kinerja model. Pengujian pada lingkungan simulasi yang lebih kompleks, seperti OpenAI Gym atau CARLA Simulator, dapat meningkatkan validitas hasil dan menunjukkan bagaimana algoritma RL menangani ketidakpastian di dunia nyata. Terakhir, mengevaluasi stabilitas dan efisiensi pembelajaran dari berbagai algoritma akan memberikan pemahaman yang lebih komprehensif terkait penerapan RL di bidang pengendalian otonom.

## 9. Daftar Pustaka

Bahare Kiumarsi, K. G. Vamvoudakis, H. Modares, & F. L. Lewis. (2018).

Optimal and autonomous control using reinforcement learning: A survey. *IEEE Transactions on Neural Networks and Learning Systems*, 29(6), 2042–2061.

Archit Sharma, Kelvin Xu, Nikhil Sardana, Abhishek Gupta, Karol Hausman, Sergey Levine, & Chelsea Finn. (2021).

Autonomous reinforcement learning: Formalism and benchmarking. *arXiv preprint arXiv:2112.09605*.

Frank L. Lewis, D. Vrabie, & V. Syrmos. (2012). *Optimal control* (3rd ed.). John Wiley and Sons.

---